프로젝트 준비 및 학습과 데이터셋 실습

참고 프로젝트 분석
데이터셋 실습

화성의과학대학교 김정은

참고 프로젝트 분석

참고 프로젝트 분석 md 파일 작성

- 프로젝트 repository 생성 (1명만)
- clone 및 collaborator 등록
- 해당 프로젝트에 md 파일로 작성된 참고 프로젝트 제안서 업로드
  - 참고 프로젝트 개요 (프로젝트의 주제 및 목표 간단한 설명)
  - 선택 이유
  - 해당 프로젝트 사용 머신러닝 기법 (머신러닝 알고리즘, 지도학습/비지도학습 여부)
  - 해당 프로젝트 데이터셋 설명

데이터셋 실습

우리가 사용할 데이터

- 도미 데이터와 빙어 데이터 직접 입력
- 각 도미, 빙어 데이터를 합쳐서 하나의 데이터셋으로 만들 것

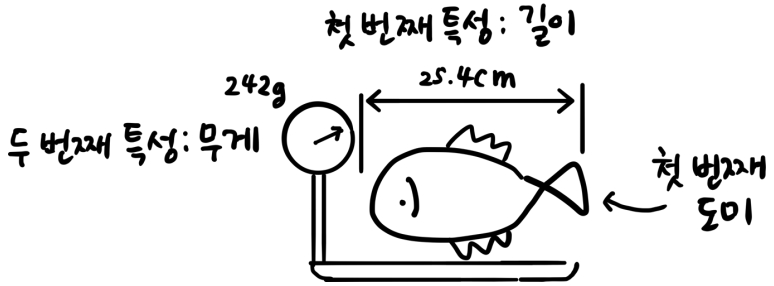

$$\text{length} = [\underbrace{25.4,\ 26.3,\ \ldots,\ 41.0}_{\text{도미 35개의 길이}},\ \underbrace{9.8,\ \ldots,\ 15.0}_{\text{빙어 14개의 길이}}]$$

$$\text{weight} = [\underbrace{242.0,\ 290.0,\ \ldots,\ 950.0}_{\text{도미 35개의 무게}},\ \underbrace{6.7,\ \ldots,\ 19.9}_{\text{빙어 14개의 무게}}]$$

→ 49개의 생선

$$\begin{array}{cc} \text{길이} & \text{무게} \\ \end{array}$$

$$\left\{\begin{array}{cc} [[25.4, & 242.0], \\ [26.3, & 290.0], \\ . & . \\ . & . \\ . & . \\ [15.0, & 19.9]] \end{array}\right.$$

Python 리스트 내포

- 대괄호 [] 안에 for 반복문과 if 조건문을 사용하여 기존 리스트나 반복 가능한 객체로부터 새로운 리스트를 한 줄로 생성
- [표현식 for 항목 in 반복가능객체 if 조건문]

```
length = bream_length+smelt_length
weight = bream_weight+smelt_weight

fish_data = [[l, w] for l, w in zip(length, weight)]
```

```
[[25.4, 242.0], [26.3, 290.0], [26.5, 340.0], [29.0, 363.0], [29.0, 430.0],
[29.7, 450.0], [29.7, 500.0], [30.0, 390.0], [30.0, 450.0], [30.7, 500.0],
[31.0, 475.0], [31.0, 500.0], [31.5, 500.0], [32.0, 340.0], [32.0, 600.0],
[32.0, 600.0], [33.0, 700.0], [33.0, 700.0], [33.5, 610.0], [33.5, 650.0],
[34.0, 575.0], [34.0, 685.0], [34.5, 620.0], [35.0, 680.0], [35.0, 700.0],
[35.0, 725.0], [35.0, 720.0], [36.0, 714.0], [36.0, 850.0], [37.0, 1000.0],
[38.5, 920.0], [38.5, 955.0], [39.5, 925.0], [41.0, 975.0], [41.0, 950.0],
[9.8, 6.7], [10.5, 7.5], [10.6, 7.0], [11.0, 9.7], [11.2, 9.8], [11.3, 8.7],
[11.8, 10.0], [11.8, 9.9], [12.0, 9.8], [12.2, 12.2], [12.4, 13.4],
[13.0, 12.2], [14.3, 19.7], [15.0, 19.9]]
```

학습 및 평가

- KNN : 일반적인 머신러닝처럼 y=Wx+b를 찾아내는 과정은 없지만 과거의 데이터를 기준으로 새로운 정답을 분류하는 알고리즘
- score : 모델이 샘플 중 얼마나 맞췄는지 평가하는 함수
- 정확도가 100%가 나온 이유 생각해보기

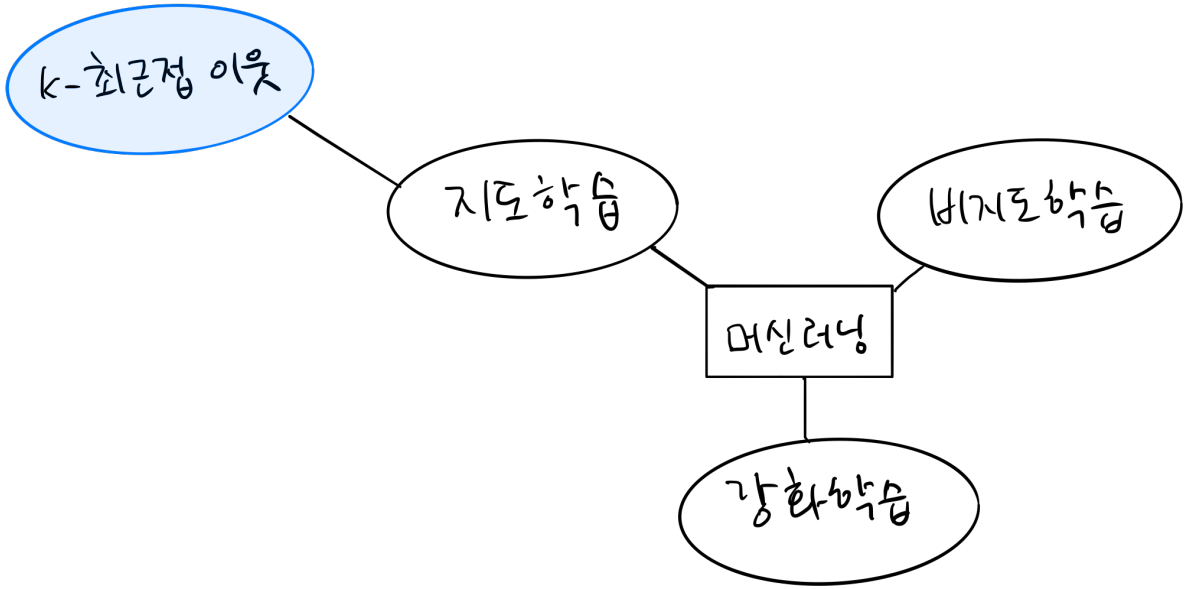

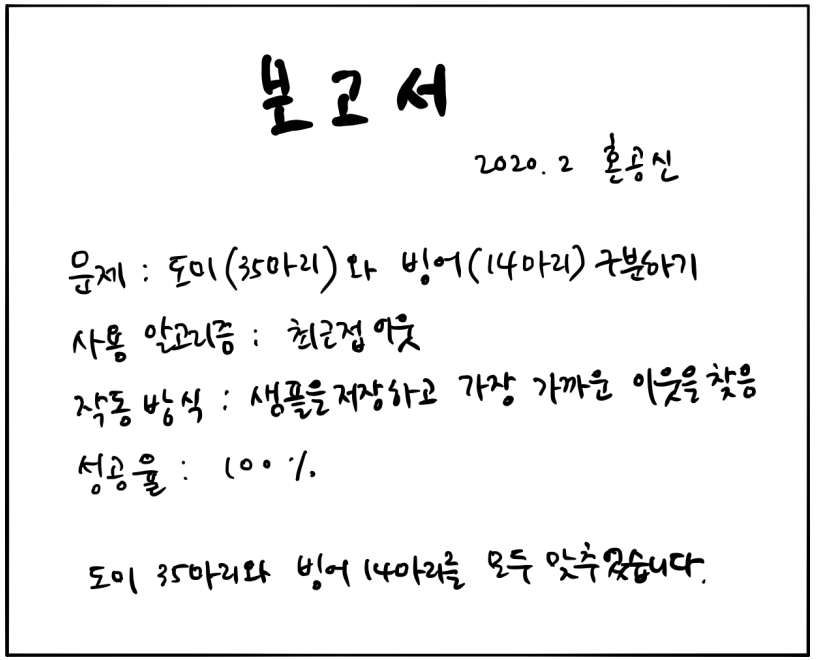

보고서

2020. 2 홍공신

문제 : 도미(35마리)와 빙어(14마리) 구분하기

사용 알고리즘 : 최근접 이웃

작동 방식 : 샘플을 저장하고 가장 가까운 이웃을 찾음

성공률 : 100%

도미 35마리와 빙어 14마리를 모두 맞추었습니다.

실습 1 : Fish Classification

- https://github.com/hsmu-jeongeun/machine-learning-practice/blob/main/01_fish_classification.ipynb
- 깃허브 해당 파일 open in colab 후 사본 드라이브에 저장
- 확인 문제 : 왜 18개부터 100% 정확도에 미치지 못하는지 생각해보고 텍스트셀로 이유 작성하여 깃허브 업로드

확인 문제

In [21]:

```
kn = KNeighborsClassifier()
kn.fit(fish_data, fish_target)

for n in range(5, 50):
    # 최근접 이웃 개수 설정
    # kn.n_neighbors = ?
    # 점수 계산
    # score = kn.score( ?, ?)
    # 100% 정확도에 미치지 못하는 이웃 개수 출력
    if score < 1:
        print(n, score)
        break
```

```
18 0.9795918367346939
```

기존 코드의 문제점

- 정확도가 100%인 도미 분류 문제
- 시험 문제를 족보에서 그대로 낸 케이스 (=훈련할 때 사용한 데이터를 평가할 때도 사용한 케이스)
- 수학 문제 해설만 달달 외워서 실제 수학시험에서 100점을 받을 수 없음
- 과적합 문제, Overfitting됨

훈련 데이터셋과 테스트 데이터셋 나누기

- 족보에 없는 문제를 낸다면 실제 똑똑하게 학습했는지 정확히 평가할 수 있을 것
- 아래와 같이 순서대로 훈련 데이터셋과 테스트 데이터셋을 나눈다면 제대로 평가할 수 있을까?

2개의 특성

49개 샘플

$$\begin{bmatrix} [25.4, & 242.0], \\ [26.3, & 290.0], \\ \vdots & \vdots \\ [15.0, & 19.9] \end{bmatrix}$$

훈련 세트 35개

테스트 세트 14개

```
train_input = fish_data[:35]
train_target = fish_target[:35]

test_input = fish_data[35:]
test_target = fish_target[35:]
```

데이터셋의 편향

- 모델 평가 시 사용하는 테스트 데이터에 도미 데이터만 들어간다면 정확도는 0이 될 것
- 각 데이터마다 편향되지 않도록 섞어주는 과정 필요

```
from sklearn.neighbors import KNeighborsClassifier

kn = KNeighborsClassifier()
kn = kn.fit(train_input, train_target)

kn.score(test_input, test_target)
0.0
```

데이터셋의 편향

- test_size=0.2 → 20%를 테스트 데이터로 사용
- random_state=42 → 재현 가능한 결과를 위해 랜덤 시드 고정
- train_test_split()을 사용하면 간단하게 데이터 분할 가능

```python
from sklearn.model_selection import train_test_split
from sklearn.datasets import load_iris
import pandas as pd

# 데이터 불러오기
iris = load_iris()
X = iris.data
y = iris.target

# 데이터를 80:20 비율로 나누기 (학습:테스트)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, \
  random_state=42)

print("학습 데이터 크기:", X_train.shape)
print("테스트 데이터 크기:", X_test.shape)
```

한계점

- 데이터가 적을 경우 훈련 데이터, 테스트 데이터, 검증 데이터로 구분할 수 없음
- K Fold 교차 검증 방식 이용

실습 2 : Train Dataset, Test Dataset

- https://github.com/hsmu-jeongeun/machine-learning-practice/blob/main/02_train_dataset_test_dataset.ipynb
- 깃허브 해당 파일 open in colab 후 사본 드라이브에 저장
- 주석 추가 후 업로드